

Министерство образования и науки Российской Федерации
Московский физико-технический институт (государственный университет)

Физтех-школа радиотехники и компьютерных технологий
Кафедра интеллектуальных информационных систем и технологий

Выпускная квалификационная работа бакалавра

Исследование методов классификации новостных сообщений

Автор:

Студент группы Б01-106а
Филак Александр

Научный руководитель:

научная степень
Харламов Александр Александрович

Научный консультант:

научная степень

-



Москва 2026

Содержание

1	Введение	4
2	Теоретическое введение	6
2.1	Анонимизация как задача управляемой замены идентичности	6
2.2	Общая схема конвейера замены лиц	7
2.3	Архитектурные принципы моделей замены лиц	9
2.3.1	SimSwap	9
2.3.2	HyperSwap 1a и HyperSwap 1c	10
2.3.3	InSwapper FP16	13
2.4	Сегментация лица и модель <code>bisenet_resnet_34</code>	15
2.5	Модели распознавания лиц как инструмент оценки анонимизации	16
2.5.1	ArcFace	17
2.5.2	AdaFace	17
2.5.3	Эмбединговое пространство и интерпретация результатов	18
3	Методика эксперимента	19

1 Введение

В современных цифровых коммуникациях фотография перестала быть только средством визуальной иллюстрации и превратилась в насыщенный носитель персональных данных. В одном изображении одновременно содержатся сведения о внешности человека, его возрасте, поле, эмоциональном состоянии, социальном окружении, месте и обстоятельствах съемки. Даже при отсутствии текстовых метаданных лицо на фотографии нередко остается устойчивым биометрическим идентификатором, по которому возможно связать изображение с другими публикациями, профилями в социальных сетях и ранее накопленными массивами визуальных данных [12, 14]. По этой причине задача анонимизации фотографий людей сегодня относится не только к области технической обработки изображений, но и к более широкой проблеме защиты частной жизни в цифровой среде.

Актуальность этой задачи усиливается ростом доступности инструментов автоматического поиска и сопоставления визуальной информации. Методы OSINT, ориентированные на поиск открытых данных о человеке, все чаще используют изображения как начальную точку расследования. Наличие одной фотографии может быть достаточным для поиска совпадений в общедоступных источниках, установления связей между аккаунтами на разных площадках и построения более полного цифрового профиля субъекта. В работе FoggySight показано, что крупномасштабные системы поиска по лицам, обученные на изображениях из открытых интернет-источников, создают реальную угрозу массовой деанонимизации пользователей, поскольку позволяют использовать фотографию как ключ к извлечению дополнительной персональной информации [4]. Тем самым визуальная приватность оказывается под угрозой даже в тех случаях, когда пользователь явно не раскрывает о себе текстовые сведения.

Отдельную роль в усилении этих рисков сыграло развитие автоматического распознавания лиц. Для крупных цифровых платформ лицо является удобным индексом, по которому можно организовывать фотоархивы, рекомендовать теги, объединять снимки одного и того же человека и строить механизмы персонализированного поиска. Одним из знаковых этапов в этом направлении стала система DeepFace, продемонстрировавшая, что современные глубокие нейронные сети способны достигать очень высокой точности верификации лиц на сложных, неконтролируемых изображениях, характерных именно для фотографий из социальных сетей [14]. Дальнейшее развитие архитектур и функций потерь привело к появлению моделей, для которых различение близких по внешности лиц в сложных условиях освещения, позы и частичных окклюзий стало стандартной практической задачей [3, 9]. В результате публикация изображения группы людей в сети может затрагивать приватность не только автора снимка, но и всех людей, попавших в кадр.

Проблема особенно заметна в сценариях, где изображение необходимо сохранить как содержательный документ, но при этом исключить или существенно затруднить идентификацию конкретного человека. К таким сценариям относятся журналистские публикации, материалы расследований, судебная и правоохранительная практика, медицинские кейсы, образовательные материалы, публикация датасетов для научных экспериментов, корпоративная отчетность и пользовательский контент в открытых сетях. Во всех перечисленных случаях важно сохранить общую информативность фотографии: позу, жесты, расположение объектов в сцене, взаимодействие людей между собой и эмоциональный контекст. Однако сохранение исходного лица в кадре может прямо противоречить требованиям приватности, законодательства и профессиональной этики.

Традиционные методы анонимизации изображений решают эту задачу лишь частично. На практике чаще всего применяются пикселизация, гауссово размытие, наложение непрозрачной маски или заполнение области лица однотонным прямоугольником. Такие приемы просты в реализации и визуально сигнализируют, что личность скрыта, однако именно эта грубость и составляет их основное ограничение. Во-первых, они ухудшают эстетическое качество изображения и нарушают композиционную целостность сцены. Во-вторых, грубое искажение немедленно демонстрирует факт цензурирования и тем самым привлекает дополнительное внимание к скрытому

объекту. В-третьих, подобные методы не всегда обеспечивают надежную защиту от современных алгоритмов, способных использовать периферийные признаки, контекст и остаточную геометрию лица. В работе, посвященной естественной и эффективной обфускации лиц, показано, что наивные способы сокрытия лица часто проигрывают более продуманным генеративным подходам, если оценка проводится не только визуально, но и с точки зрения последующего распознавания [13]. Сходные выводы содержатся и в обзорах по деидентификации лиц, где подчеркивается, что простое искажение изображения не всегда устраняет биометрическую связь с исходной личностью [12].

Недостаточность традиционных способов особенно заметна, если различать два уровня угроз. Первый уровень связан с человеческим наблюдателем: необходимо сделать так, чтобы зритель не мог непосредственно узнать человека на изображении. Второй уровень связан с автоматической системой: необходимо изменить изображение настолько, чтобы модель распознавания перестала связывать его с исходной личностью. Между этими двумя уровнями нет полного совпадения. Человек может не узнать лицо после размытия, тогда как обученная нейросетевая система, использующая статистически устойчивые признаки, все еще сможет извлечь часть идентификационной информации. Именно поэтому в современных работах по *privacy-preserving face processing* визуальная скрытость не рассматривается как достаточный критерий анонимизации [12, 10].

Еще одна проблема классических методов состоит в том, что они плохо согласуются с потребностями дальнейшего машинного анализа изображений. В ряде практических сценариев фотография после анонимизации должна оставаться пригодной для компьютерного зрения: например, для анализа позы человека, социальных взаимодействий в кадре, плотности потока людей или структуры окружающей сцены. Грубое закрашивание или размытие лица разрушает локальную статистику изображения и может влиять на работу последующих моделей анализа. Генеративная анонимизация, напротив, потенциально способна сохранить естественную структуру изображения лучше, чем прямое удаление области лица, что делает ее привлекательной не только с точки зрения визуальной эстетики, но и с точки зрения дальнейшей алгоритмической обработки.

Таким образом, в задаче анонимизации возникает принципиальное противоречие. С одной стороны, требуется достаточно сильно изменить биометрически значимые признаки лица, чтобы затруднить как человеческую, так и автоматическую идентификацию. С другой стороны, итоговое изображение должно оставаться реалистичным, визуально цельным и пригодным для последующего использования в публикациях, отчетах и цифровых продуктах. Чем сильнее и грубее искажение, тем надежнее может казаться сокрытие личности, но тем меньше практическая ценность полученного изображения. И наоборот, слишком деликатная обработка способна сохранить приятный внешний вид снимка, но оказаться недостаточной с точки зрения защиты приватности.

Нейросетевые методы открывают возможность снять это противоречие за счет более содержательного преобразования изображения. В отличие от классических техник, которые просто удаляют или деградируют часть визуальной информации, генеративные модели могут модифицировать идентичность лица при сохранении позы, освещения, мимики и общей правдоподобности сцены. В рамках такой постановки анонимизация перестает быть задачей сокрытия области изображения и превращается в задачу управляемой деидентификации: необходимо сохранить фотографическую естественность и визуальную согласованность кадра, но разрушить связь между исходным лицом и его биометрическим представлением в пространстве признаков моделей распознавания [10, 13].

Особый интерес в этом контексте представляет замена лица как способ анонимизации. Если вместо размывания или закрашивания область лица заменяется новым, реалистично синтезированным образом, можно получить изображение, которое сохраняет смысл сцены и выглядит значительно естественнее для человеческого наблюдателя. При этом правильно построенный конвейер замены лица потенциально позволяет не просто ухудшить видимость отдельных деталей, а заменить саму идентичность, сохранив остальные атрибуты изображения. Для практических приложений такой подход ценен тем, что итоговый снимок не выглядит грубо отредактированным и может использоваться в контекстах, где внешний вид изображения имеет существенное значение.

Однако визуальная правдоподобность сама по себе еще не означает успешной анонимизации.

Генеративная модель может построить правдоподобное лицо, которое субъективно воспринимается как другое, но в пространстве эмбедингов современных систем распознавания все еще оставаться близким к исходному человеку. Поэтому оценка анонимизации должна опираться не только на визуальное впечатление, но и на количественный анализ того, насколько меняется положение изображения в биометрическом признаковом пространстве. Именно здесь становятся критически важными современные модели распознавания лиц, такие как ArcFace и AdaFace, которые позволяют измерять сходство между исходными и анонимизированными фотографиями не на уровне пикселей, а на уровне высокоуровневых представлений идентичности [3, 9].

В настоящей работе рассматривается подход к анонимизации фотографий людей, основанный на нейросетевой замене лиц в рамках конвейера FaceFusion. В данном подходе лица реальных людей подменяются одним и тем же сгенерированным референсным лицом, что позволяет целенаправленно разрушать исходную идентичность при сохранении визуальной целостности изображения. Такой дизайн эксперимента удобен тем, что он переводит задачу анонимизации из класса случайных стилистических преобразований в более контролируемую процедуру: для множества различных исходных лиц задается единая целевая идентичность, а затем оценивается, насколько эффективно исходные личности перестают распознаваться современными биометрическими моделями.

С научной точки зрения задача исследования состоит в анализе того, насколько современные нейросетевые методы замены лиц пригодны для анонимизации фотографий людей. Для ответа на этот вопрос необходимо рассмотреть архитектурные принципы используемых моделей, роль сегментации и маскирования лица в процессе замены, а также особенности тех моделей распознавания, которыми затем измеряется качество анонимизации. Практическая значимость работы определяется возможностью построения более естественных и менее визуально разрушительных способов защиты приватности по сравнению с традиционными методами сокрытия лиц.

2 Теоретическое введение

2.1 Анонимизация как задача управляемой замены идентичности

В задачах обработки визуальных персональных данных полезно различать сокрытие лица и деидентификацию лица. Сокрытие, реализуемое размытием, пикселизацией или маской, ориентировано прежде всего на подавление части исходной визуальной информации. Деидентификация же ставит более содержательную цель: преобразовать изображение таким образом, чтобы человек и алгоритм распознавания не могли надежно связать результат с исходной личностью, но при этом сама фотография сохраняла реалистичность и контекст сцены. В литературе по *privacy-preserving face processing* подчеркивается, что именно этот второй вариант становится особенно важным в условиях стремительного роста качества face recognition систем [12, 10].

Если описывать задачу формально, исходное изображение лица можно представить как случайную величину x , содержащую смесь факторов различной природы: идентичность человека, геометрию головы, мимику, освещение, фон, качество съемки и артефакты сенсора. Цель анонимизации состоит не просто в том, чтобы получить другое изображение $\tilde{x}$, а в том, чтобы биометрические признаки $\phi(\tilde{x})$ стали достаточно далеки от $\phi(x)$ в пространстве признаков модели распознавания $\phi(\cdot)$, сохранив при этом визуально правдоподобные факторы, не связанные напрямую с идентичностью. Тем самым анонимизация в рассматриваемой постановке есть задача контролируемой декорреляции между идентичностью и остальными визуальными атрибутами лица.

Такое представление подчеркивает, что успешная анонимизация не равна произвольному искажению. Если преобразование разрушает не только идентичность, но и позу, мимику, распределение света или связи лица с остальной сценой, оно может выполнять задачу деидентификации, но окажется непригодным для практического использования. Следовательно, модель анонимизации должна уметь разделять факторы, подлежащие изменению, и факторы, которые желательно сохранить. В

терминах обучения представлениям это означает необходимость частичного разделения признаков идентичности и признаков, описывающих структуру кадра. Модели замены лиц оказываются естественным инструментом для такой постановки, поскольку они изначально проектируются на перенос одного фактора — идентичности — при максимально возможном сохранении других.

Эту идею можно выразить и как задачу многокритериальной оптимизации. Пусть $\mathcal{R}(\tilde{x})$ обозначает меру узнаваемости анонимизированного изображения системой распознавания, а $\mathcal{Q}(x, \tilde{x})$ — меру сохранения полезных визуальных свойств исходной фотографии. Тогда деидентификацию естественно рассматривать как решение задачи

$$\tilde{x}^* = \arg \min_{\tilde{x}} \left(\mathcal{R}(\tilde{x}; x) - \lambda \mathcal{Q}(x, \tilde{x}) \right), \quad (1)$$

где параметр $\lambda > 0$ задает компромисс между приватностью и визуальной сохранностью. В качестве $\mathcal{R}$ может выступать, например, косинусное сходство между эмбедингами исходного и преобразованного лица, тогда как $\mathcal{Q}$ может включать структурное сходство, перцептуальные признаки или ограничения на сохранение контекста сцены.

Если в явном виде использовать модель распознавания лиц $\phi(\cdot)$, то естественным кандидатом на функцию идентифицируемости является

$$\mathcal{R}(\tilde{x}; x) = \frac{\phi(\tilde{x})^\top \phi(x)}{\|\phi(\tilde{x})\|_2 \|\phi(x)\|_2}. \quad (2)$$

В таком виде задача анонимизации напрямую связывается с геометрией эмбедингового пространства: чем меньше косинусное сходство между исходным и преобразованным лицом, тем слабее их биометрическая связь. Одновременно ограничения на качество результата можно записать через семейство сохраняемых атрибутов $\psi(\cdot)$:

$$\mathcal{Q}(x, \tilde{x}) = -\|\psi(\tilde{x}) - \psi(x)\|_1, \quad (3)$$

где оператор $\psi(\cdot)$ может кодировать позу, выражение лица, освещение или структуру сцены. Такой взгляд особенно удобен для обоснования использования именно замены лица: модель не должна максимизировать отличие во всех аспектах, а должна преимущественно разрушать идентичность, сохраняя нерелевантные к ней характеристики изображения.

На практике это приводит к популярной схеме, где исходная идентичность источника кодируется в компактное представление, затем это представление либо заменяется другим, либо смешивается с признаками целевого изображения, а на выходе генератор восстанавливает новое лицо с сохранением позы и выражения. Такая схема особенно естественно реализуется в конвейере замены лиц, где разделяются роль исходного лица-донора идентичности и роль целевого изображения, задающего позу, освещение и контекст сцены [1, 5].

2.2 Общая схема конвейера замены лиц

Независимо от конкретной модели, современные системы замены лиц обычно строятся как многоэтапный конвейер. На первом этапе выполняются обнаружение и геометрическое выравнивание лица. Цель этого шага состоит в том, чтобы привести лицо к каноническому положению, уменьшив вариации масштаба, поворота и перспективного искажения. На втором этапе формируется представление идентичности исходного лица, как правило в виде эмбединга, вычисленного отдельной моделью распознавания лиц. На третьем этапе генеративная сеть синтезирует новое лицо, совмещая идентичность источника с позой и локальной структурой лица в целевом изображении. На четвертом этапе применяется маска лица, полученная отдельной моделью сегментации или парсинга, после чего синтезированная область аккуратно встраивается обратно в исходный кадр.

Такой конвейер отражает фундаментальную идею декомпозиции задачи на несколько подзадач: локализацию, нормализацию геометрии, кодирование идентичности, генерацию и бесшовное

смешивание. Наличие отдельного шага сегментации особенно важно для практической анонимизации, поскольку даже хорошо синтезированное лицо может визуальнo разрушить изображение, если границы замены не согласованы с контуром кожи, волос, ушей и прилегающих областей. Поэтому качество итогового результата определяется не только генератором, но и точностью маски, задающей область слияния синтезированного и исходного изображения.

Формально работу такого конвейера можно описать как композицию нескольких отображений. Пусть x_s обозначает изображение лица-источника, задающего целевую идентичность, а x_t — целевое изображение, в котором эта идентичность должна быть реализована. Тогда после выравнивания и нормализации можно записать

$$\hat{x}_s = A_s(x_s), \quad \hat{x}_t = A_t(x_t), \quad (4)$$

где A_s и A_t обозначают операторы обнаружения, выделения и геометрического приведения лиц к каноническому виду. Далее модель распознавания лиц $E(\cdot)$ извлекает эмбединг идентичности

$$z_s = E(\hat{x}_s), \quad z_s \in \mathbb{R}^d. \quad (5)$$

Генератор $G(\cdot, \cdot)$ получает на вход эмбединг источника и нормализованное целевое лицо и строит синтезированную область

$$\tilde{x}_t = G(z_s, \hat{x}_t). \quad (6)$$

После этого модель сегментации или маскирования $M(\cdot)$ предсказывает маску области смешивания $m \in [0, 1]^{H \times W}$, и итоговый результат в локализованной области может быть записан как

$$y_t = m \odot \tilde{x}_t + (1 - m) \odot \hat{x}_t, \quad (7)$$

где $\odot$ обозначает поэлементное умножение. Такая запись полезна тем, что она явно разделяет вклад блока идентичности, генератора и маскирующего модуля.

Сам шаг выравнивания также удобно описывать в явном виде. Если $\mathbf{u} = (u, v, 1)^\top$ обозначает однородные координаты пикселя, а матрица аффинного преобразования задается как

$$T_\theta = \begin{pmatrix} a_{11} & a_{12} & t_x \\ a_{21} & a_{22} & t_y \\ 0 & 0 & 1 \end{pmatrix}, \quad (8)$$

то канонически выровненное лицо строится выборкой

$$\hat{x}(\mathbf{u}) = x(T_\theta \mathbf{u}). \quad (9)$$

Величины $a_{11}, a_{12}, a_{21}, a_{22}$ и t_x, t_y определяются по набору лицевых ориентиров. В практических реализациях это позволяет приводить к общей системе координат положение глаз, носа и рта, уменьшая вариативность, не связанную с идентичностью.

С вычислительной точки зрения полезно заметить, что перечисленные стадии соответствуют различным типам инвариантности. Этап обнаружения и выравнивания стремится сделать последующие модули инвариантными к масштабу и повороту лица. Этап извлечения эмбединга идентичности должен, напротив, сохранять индивидуальные признаки человека, подавляя случайные вариации освещения и мимики. Генератор обязан совместить эти два требования: принять устойчивое описание идентичности и встроить его в изображение, подчиненное позе и локальной геометрии целевой сцены. Наконец, маскирование и смешивание вводят уже не семантическую, а пространственную согласованность, отвечая за визуальнo непрерывный переход между синтезированной областью и неизменной частью кадра.

В используемом в данной работе конвейере FaceFusion центральную роль играют модели замены лиц HyperSwap 1a, HyperSwap 1c, InSwapper FP16 и SimSwap 512, а для выделения области лица используется модель сегментации `bisenet_resnet_34`. Несмотря на различие в реализации и степени открытости архитектурных деталей, перечисленные модели можно описать в терминах общей парадигмы генерации, обусловленной идентичностью: имеется внешний или встроенный блок получения идентичностного представления, а сама генерация ориентирована на перенос идентичности на целевое лицо с сохранением позы и локального контекста сцены.

Если перейти к постановке обучения, то типичная задача модели замены лиц сводится к минимизации комбинированного функционала

$$\mathcal{L}_{\text{total}} = \lambda_{\text{adv}}\mathcal{L}_{\text{adv}} + \lambda_{\text{id}}\mathcal{L}_{\text{id}} + \lambda_{\text{rec}}\mathcal{L}_{\text{rec}} + \lambda_{\text{feat}}\mathcal{L}_{\text{feat}} + \lambda_{\text{mask}}\mathcal{L}_{\text{mask}}, \quad (10)$$

где отдельные слагаемые отвечают, соответственно, за фотореализм, перенос идентичности, реконструкцию, сохранение промежуточных признаков и качество маскирования. Набор конкретных членов зависит от модели, однако сама многокритериальная природа оптимизации является общей для большинства современных систем замены лиц.

При этом состязательное слагаемое в типичном случае принимает форму минимаксной задачи

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z_s, x_t} [\log(1 - D(G(z_s, x_t)))], \quad (11)$$

где генератор стремится построить неотличимое от реального изображение, а дискриминатор — обнаружить синтетическое происхождение результата. Для face swap задачи это взаимодействие важно не само по себе, а как средство сохранить реалистичную текстуру кожи, локальные тени и естественную микроструктуру лица, которые трудно выразить только пиксельной реконструкцией.

2.3 Архитектурные принципы моделей замены лиц

2.3.1 SimSwap

SimSwap является одной из наиболее подробно описанных в академической литературе универсальных моделей замены лиц. В работе Chen et al. модель позиционируется как система переноса идентичности, рассчитанная на замену лица без необходимости обучения отдельной сети под конкретную пару людей [1]. Ключевая идея заключается в том, чтобы использовать компактный идентичностный вектор, извлеченный из исходного лица, и внедрять его в генератор, который получает также целевое изображение и восстанавливает лицо с новой идентичностью, но с сохранением позы и выражения целевого кадра.

Архитектурно SimSwap состоит из нескольких логических компонентов. Сначала отдельная сеть распознавания извлекает из исходного изображения вектор идентичности. Далее этот вектор передается в так называемый ID Injection Module, через который генератор получает информацию о том, чью именно идентичность следует перенести. Сам генератор строится как encoder-decoder сеть с пропуском локальной структуры целевого изображения. Для повышения визуальной достоверности используется дискриминатор, а обучение опирается не только на состязательный сигнал, но и на ограничения, связанные с сохранением идентичности и структуры лица [1].

Важно, что SimSwap задуман как универсальный подход, не привязанный к фиксированному набору источников. Это отличает его от более ранних методов, ориентированных на обучение под конкретные пары лиц или на перенос в рамках ограниченного множества идентичностей. Для задач анонимизации это свойство особенно существенно: модель должна уметь работать с широким спектром реальных лиц без дополнительной подстройки под конкретного человека. Универсальность SimSwap достигается именно благодаря отделению эмбединга идентичности от генеративной части, что позволяет подставлять в один и тот же конвейер разные референсные лица и применять модель к разнообразным целевым изображениям.

Одной из ключевых особенностей SimSwap является использование Weak Feature Matching Loss. В классической постановке замены лиц задача сталкивается с конфликтом: слишком жесткое требование восстановить пиксельно близкое изображение может мешать переносу идентичности, тогда как чисто состязательное обучение может ухудшать стабильность генерации. Авторы SimSwap предлагают ослабленное сопоставление признаков, которое лучше согласуется с тем, что итоговое лицо должно быть одновременно похоже на источник по идентичности и на цель по геометрии и локальной сцене [1]. Для практики анонимизации это важно, поскольку такой баланс позволяет модифицировать биометрически значимые признаки без грубого разрушения естественности изображения.

Если записать основную логику обучения SimSwap более формально, то можно выделить по крайней мере три характерных ограничения. Во-первых, используется состязательное слагаемое

$$\mathcal{L}_{\text{adv}} = \mathbb{E}_x[\log D(x)] + \mathbb{E}_{x_s, x_t}[\log(1 - D(G(E(x_s), x_t)))], \quad (12)$$

где $D(\cdot)$ есть дискриминатор, отличающий реальные изображения от синтезированных. Во-вторых, вводится идентичностное ограничение

$$\mathcal{L}_{\text{id}} = \left\| \frac{E(G(E(x_s), x_t))}{\|E(G(E(x_s), x_t))\|_2} - \frac{E(x_s)}{\|E(x_s)\|_2} \right\|_2^2, \quad (13)$$

которое стремится сохранить близость между эмбедингом сгенерированного лица и эмбедингом источника. Наконец, ослабленное сопоставление признаков можно интерпретировать как ограничение на согласование промежуточных активаций дискриминатора или вспомогательного экстрактора признаков:

$$\mathcal{L}_{\text{wfm}} = \sum_{l=1}^L \alpha_l \|\psi_l(x_t) - \psi_l(G(E(x_s), x_t))\|_1, \quad (14)$$

где $\psi_l(\cdot)$ обозначает признаки l -го уровня. В отличие от жесткой реконструкции всего изображения, такое ограничение позволяет удерживать локальную структуру и текстурную согласованность без требования точного восстановления исходного лица.

Используемая в эксперименте конфигурация SimSwap 512 не образует отдельную архитектурную семью по сравнению с базовой опубликованной моделью, а представляет собой высокоразрешающую конфигурацию того же подхода. В официальном репозитории SimSwap для режима 512 пикселей сохраняется общий принцип: идентичность кодируется отдельно, затем внедряется в генератор, а высокое разрешение используется для повышения локальной детализации и уменьшения заметности артефактов по краям области замены [11]. Поэтому в теоретическом анализе корректно рассматривать SimSwap 512 как вариант одной и той же генеративной архитектуры, обусловленной идентичностью.

2.3.2 HyperSwap 1a и HyperSwap 1c

Модели HyperSwap 1a и HyperSwap 1c входят в экосистему FaceFusion Labs и относятся к современной GAN-ориентированной линии систем замены лиц. В отличие от SimSwap, для HyperSwap на момент подготовки работы не существует широко цитируемой рецензируемой статьи, подробно описывающей модель; основным техническим источником выступает официальная документация проекта и связанный с ней открытый код [5, 2]. Именно поэтому при анализе HyperSwap необходимо опираться на подтверждаемые архитектурные параметры, а не на неформальные описания из вторичных публикаций.

Согласно официальной документации, HyperSwap реализует схему generator-discriminator с отдельным использованием эмбединга лица источника. Генератор принимает идентичностное представление источника и целевое лицо, после чего синтезирует замененную область. Для

генератора указываются входные каналы идентичности размерности 512, выходные каналы 4096, размер выхода 256×256 и два основных обрабатывающих блока. Дискриминатор построен как многомасштабная сеть с тремя дискриминаторами, пятью сверточными слоями на каждой шкале, базовым числом фильтров 64 и ядром 4 [2]. Многомасштабная постановка здесь принципиальна: один дискриминатор может контролировать глобальную согласованность формы и освещения, тогда как другие ответственны за более локальные детали.

Система HyperSwar также включает отдельный face masker, который принимает многоканальное представление и предсказывает одноканальную маску смешивания. Наличие выделенного модуля маскирования указывает, что авторы модели трактуют реалистичность замены лица не только как задачу синтеза центральной части лица, но и как задачу корректной интеграции результата обратно в изображение [2]. Для анонимизации это особенно важно: если генератор убедительно меняет идентичность, но маска срабатывает грубо, итоговое изображение остается очевидно отредактированным и менее пригодным для практического использования.

С инженерной точки зрения HyperSwar интересен еще и тем, что в его описании отчетливо видна ориентация на прикладной конвейер, а не только на академическую демонстрацию принципа. Наличие отдельного набора warp templates, специализированного masker-модуля и нескольких семейств потерь указывает, что система оптимизируется под устойчивую работу на реальных изображениях с разнообразной геометрией лица [2]. Для дипломной работы это важно методологически: использование таких моделей позволяет обсуждать анонимизацию не как лабораторный пример, а как потенциально прикладную технологию, в которой качество границ, стабильность работы и визуальная непрерывность не менее важны, чем формальный перенос идентичности.

В тренировочной постановке HyperSwar использует набор специализированных функций потерь, в который, согласно документации, входят adversarial loss, cycle loss, feature loss, reconstruction loss, identity loss, gaze loss и mask loss [2]. Такая совокупность ограничений отражает многокритериальную природу задачи. Identity loss удерживает связь результата с референсной идентичностью, reconstruction и feature losses стабилизируют генерацию, adversarial loss отвечает за фотореализм, gaze loss помогает не разрушать направление взгляда, а mask loss повышает качество стыка между синтезированной и исходной областью. В теоретическом плане HyperSwar можно рассматривать как расширение классической encoder-generator-discriminator схемы, в которой отдельное внимание уделяется бесшовной интеграции лица и тонкой настройке баланса между идентичностью и визуальной правдоподобностью.

В удобной абстрактной форме такую систему можно представить как минимизацию функционала

$$\mathcal{L}_{\text{HyperSwar}} = \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} + \lambda_{\text{cyc}} \mathcal{L}_{\text{cyc}} + \lambda_{\text{feat}} \mathcal{L}_{\text{feat}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{id}} \mathcal{L}_{\text{id}} + \lambda_{\text{gaze}} \mathcal{L}_{\text{gaze}} + \lambda_{\text{mask}} \mathcal{L}_{\text{mask}}. \quad (15)$$

Здесь циклическое ограничение может быть записано как

$$\mathcal{L}_{\text{cyc}} = \|x_t - G(E(x_t), G(E(x_s), x_t))\|_1, \quad (16)$$

то есть как требование, чтобы после обратного переноса идентичности восстанавливалось исходное целевое лицо. Такая конструкция не является обязательной для всех моделей замены лиц, но хорошо иллюстрирует, как в HyperSwar усиливается контроль согласованности преобразования.

Более детально отдельные компоненты этого функционала также допускают явную формализацию. Идентичностное ограничение удобно задавать через косинусное сходство эмбеддингов:

$$\mathcal{L}_{\text{id}} = 1 - \frac{E(y)^\top E(x_s)}{\|E(y)\|_2 \|E(x_s)\|_2}, \quad (17)$$

где $y = G(E(x_s), x_t)$ — сгенерированное изображение. Такая форма подчеркивает, что генератор должен не просто синтезировать правдоподобное лицо, а именно переносить идентичность источника в терминах признакового пространства модели распознавания.

Реконструкционное ограничение можно записать как

$$\mathcal{L}_{\text{rec}} = \|G(E(x_t), x_t) - x_t\|_1. \quad (18)$$

Здесь идея состоит в том, что если источником идентичности служит само целевое лицо, то генератор должен уметь приблизительно восстановить исходное изображение без лишних искажений. Это ограничение снижает риск того, что сеть начнет решать задачу замены лица через избыточно агрессивное изменение текстур и геометрии.

Потеря признаков естественно задается через промежуточные представления вспомогательной сети $\varphi_l(\cdot)$:

$$\mathcal{L}_{\text{feat}} = \sum_{l=1}^L \alpha_l \|\varphi_l(y) - \varphi_l(x_t)\|_1. \quad (19)$$

Она отвечает за сохранение локальной и глобальной структуры изображения на нескольких уровнях абстракции. В отличие от чисто пиксельной реконструкции, такая функция помогает удерживать естественные переходы текстур и освещения, не требуя точного совпадения каждой интенсивности.

Для модуля маскирования разумна постановка через бинарную кросс-энтропию

$$\mathcal{L}_{\text{mask}} = - \sum_i \left(m_i \log \hat{m}_i + (1 - m_i) \log(1 - \hat{m}_i) \right), \quad (20)$$

где m_i обозначает эталонное значение маски в пикселе i , а $\hat{m}_i$ — предсказание маскирующей сети. Если же требуется сильнее контролировать форму маски как области, а не только покомпонентную классификацию пикселей, вместо этого или совместно с этим может использоваться коэффициент Dice:

$$\mathcal{L}_{\text{dice}} = 1 - \frac{2 \sum_i m_i \hat{m}_i + \epsilon}{\sum_i m_i + \sum_i \hat{m}_i + \epsilon}. \quad (21)$$

Наконец, ограничение на направление взгляда можно интерпретировать как расстояние между признаками специализированного оценщика взгляда $H(\cdot)$:

$$\mathcal{L}_{\text{gaze}} = \|H(y) - H(x_t)\|_2^2. \quad (22)$$

В практической задаче анонимизации это слагаемое особенно полезно, поскольку направление взгляда является заметной для человека характеристикой лица: грубое нарушение глазной геометрии или несогласованность взгляда с позой головы быстро делает изображение искусственным. Таким образом, даже если точная реализация отдельных потерь в конкретных весах HyperSwap может отличаться, их математическая структура хорошо объясняет, почему модель способна одновременно контролировать идентичность, реалистичность и бесшовное смешивание.

Публичные материалы FaceFusion Labs не дают оснований считать HyperSwap 1a и HyperSwap 1c архитектурно разными семействами моделей. Напротив, доступная документация описывает общую HyperSwap architecture, а сами обозначения 1a и 1c относятся к вариантам весов и конфигураций внутри одной и той же модели [5, 2]. Поэтому в данной работе корректно рассматривать HyperSwap 1a и HyperSwap 1c как две инстанции общей архитектуры HyperSwap, а различия между ними интерпретировать на уровне обученных параметров и, возможно, специфики данных или режима обучения, но не как принципиально разные сетевые схемы.

2.3.3 InSwapper FP16

InSwapper FP16 широко используется в прикладных системах замены лиц, в том числе благодаря интеграции в экосистему InsightFace. Вместе с тем здесь возникает важная методологическая особенность: в отличие от ArcFace, по которому существует каноническая статья, и в отличие от SimSwap, по которому опубликована специализированная работа, InSwapper не сопровождается столь же подробным академическим описанием архитектуры. Официальные материалы InsightFace документируют назначение модели, формат запуска и практику использования ONNX-весов, однако не предоставляют исчерпывающего рецензируемого развертывания сетевой схемы и обучающей постановки [7].

Из подтверждаемых технических сведений следует, что InSwapper относится к тому же широкому классу систем замены лиц, обусловленных идентичностью. В системе используется отдельное представление идентичности, согласованное с экосистемой InsightFace, а сама модель выполняет перенос признаков лица источника на целевое изображение с последующим восстановлением результирующей области. Обозначение FP16 указывает прежде всего на формат чисел с плавающей точкой половинной точности при инференсе или хранении модели, а не на новую архитектурную идею. Это означает, что InSwapper FP16 следует интерпретировать как вычислительно оптимизированную реализацию уже обученной модели, пригодную для ускоренного применения на современном оборудовании.

В теоретическом разделе важно прямо зафиксировать границу доступных сведений. По публично подтверждаемым материалам InSwapper можно уверенно отнести к семейству генеративных моделей замены лиц, использующих отделенное представление идентичности и локальную замену лица. Однако детальный разбор слоев, блоков и функций потерь в строгом академическом смысле для этой модели затруднен из-за отсутствия сопоставимой по полноте официальной статьи. Поэтому далее InSwapper рассматривается как практически значимый представитель того же класса методов, что и SimSwap и HyperSwap, но с меньшей степенью архитектурной прозрачности в открытых источниках.

Несмотря на это ограничение, InSwapper удобно описывать через общую математическую схему условной генерации лица. Пусть x_s — лицо-источник идентичности, x_t — целевое лицо, $E(\cdot)$ — экстрактор идентичности, $F(\cdot)$ — кодировщик целевого изображения, а $G(\cdot)$ — декодер или генератор. Тогда сначала вычисляется эмбединг источника

$$z_s = E(x_s), \quad (23)$$

а затем кодировщик строит скрытое представление целевого лица

$$h_t = F(x_t). \quad (24)$$

Ключевой вопрос состоит в том, как именно внедрить идентичность источника в скрытое пространство цели. Для широкого класса подобных моделей это можно записать как оператор модуляции

$$\tilde{h}_t = \Psi(h_t, z_s), \quad (25)$$

после чего генератор восстанавливает изображение

$$y = G(\tilde{h}_t). \quad (26)$$

Такое представление удобно тем, что оно не навязывает одной конкретной архитектурной реализации, но при этом четко выражает главную идею: система отделяет идентичность от структуры целевого лица и затем повторно объединяет их на уровне скрытых признаков.

Оператор $\Psi(\cdot, \cdot)$ может быть реализован различными способами. Один из простейших вариантов — аддитивное внедрение идентичности в признаки некоторого уровня:

$$\tilde{h}_t^{(l)} = h_t^{(l)} + W_l z_s, \quad (27)$$

где $h_t^{(l)}$ — признаки l -го уровня, а W_l — обучаемое линейное преобразование эмбединга идентичности. Более гибкий вариант состоит в использовании аффинной модуляции признаков:

$$\tilde{h}_t^{(l)} = \gamma_l(z_s) \odot h_t^{(l)} + \beta_l(z_s), \quad (28)$$

где функции $\gamma_l(\cdot)$ и $\beta_l(\cdot)$ вычисляют масштаб и сдвиг по эмбедингу идентичности. Подобные схемы естественно интерпретируются как способ адаптировать локальные текстурные и геометрические признаки цели под новую идентичность без полного разрушения исходной позы и освещения.

Если в модели используется нормировка признаков, то модуляцию можно записать и в более общем виде

$$\tilde{h}_t^{(l)} = \gamma_l(z_s) \odot \frac{h_t^{(l)} - \mu(h_t^{(l)})}{\sigma(h_t^{(l)})} + \beta_l(z_s), \quad (29)$$

что делает механизм близким к семейству условных нормировок. Теоретически это важно потому, что идентичность тогда влияет не только на добавление некоторого сигнала, но и на статистику признаков, а значит может менять форму, пропорции и текстуру лица более согласованным образом.

С точки зрения целей обучения разумно предполагать, что класс моделей, к которому относится InSwapper, оптимизирует многокомпонентный функционал вида

$$\mathcal{L}_{\text{swap}} = \lambda_{\text{id}} \mathcal{L}_{\text{id}} + \lambda_{\text{per}} \mathcal{L}_{\text{per}} + \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} + \lambda_{\text{blend}} \mathcal{L}_{\text{blend}}, \quad (30)$$

где $\mathcal{L}_{\text{id}}$ отвечает за перенос идентичности, $\mathcal{L}_{\text{per}}$ — за перцептуальное сходство с целевой сценой, $\mathcal{L}_{\text{adv}}$ — за фотореализм, а $\mathcal{L}_{\text{blend}}$ — за качество локального смешивания. Даже если конкретные обозначения и веса в реальной модели могут отличаться, такая формализация адекватно описывает тип требований, которым должна удовлетворять практическая система замены лиц.

Например, идентичностный член можно задать через нормированные эмбединги:

$$\mathcal{L}_{\text{id}} = 1 - \frac{E(y)^\top E(x_s)}{\|E(y)\|_2 \|E(x_s)\|_2}, \quad (31)$$

а перцептуальный член — через признаки предварительно обученной сети $\phi_l(\cdot)$:

$$\mathcal{L}_{\text{per}} = \sum_{l=1}^L \|\phi_l(y) - \phi_l(x_t)\|_2^2. \quad (32)$$

Слагаемое смешивания естественно записывается как расстояние между скомпонованным результатом и целевой областью вне зоны активной замены:

$$\mathcal{L}_{\text{blend}} = \|(1 - m) \odot y - (1 - m) \odot x_t\|_1. \quad (33)$$

Такое ограничение особенно важно именно для анонимизации: если система хорошо меняет идентичность в центре лица, но создает заметные артефакты на границах щек, лба или подбородка, результат остается технически неудовлетворительным. Поэтому даже при отсутствии полной архитектурной прозрачности математическое описание класса моделей позволяет содержательно объяснить место InSwapper в общей системе методов замены лиц.

Это замечание принципиально и с точки зрения научной аккуратности. В обзорах и прикладных статьях по замене лиц нередко встречается соблазн описывать популярные практические

модели так, как если бы их архитектура была полностью известна и верифицирована. Для данной работы такой подход нежелателен. Корректнее прямо различать модели, для которых доступны строгие первичные статьи с формулами и обучающими постановками, и модели, чья архитектура восстанавливается только частично по документации, интерфейсам запуска и публичным описаниям. Такое разграничение повышает надежность теоретической части и позволяет не подменять подтвержденные сведения правдоподобными, но недоказанными интерпретациями.

2.4 Сегментация лица и модель `bisenet_resnet_34`

Качество замены лица определяется не только тем, насколько хорошо модель переносит идентичность, но и тем, насколько аккуратно она выделяет границы области, подлежащей замене. Если заменить слишком малую область, в кадре могут сохраниться фрагменты исходной идентичности. Если заменить слишком большую область, возрастает риск искажения волос, фона, ушей и других элементов, не относящихся непосредственно к лицу. Именно поэтому в современных системах широко используются модели семантической сегментации или парсинга лица, позволяющие строить точную маску для последующего смешивания.

В используемом конвейере для этих целей применяется модель `bisenet_resnet_34`. По смыслу это реализация подхода BiSeNet, в которой архитектура двупоточной сегментации сочетается с базовой сетью класса ResNet-34. Базовая идея BiSeNet, предложенная Yu et al., состоит в разделении пространственной и контекстной обработки [15]. Пространственный путь сохраняет высокое разрешение и уточняет локальные границы объектов, тогда как контекстный путь быстро уменьшает разрешение, но получает более широкое поле восприятия и семантически насыщенные признаки. Такое разделение оказывается особенно полезным в задачах сегментации лица, где необходимо одновременно точно отсекают границы глаз, губ и овала лица и при этом учитывать глобальную структуру головы.

В оригинальной архитектуре BiSeNet ключевую роль играют Spatial Path, Context Path, Attention Refinement Module и Feature Fusion Module [15]. Пространственный путь использует сравнительно неглубокую сверточную обработку с умеренным уменьшением разрешения, чтобы не потерять локальную геометрию. Контекстный путь, напротив, строится на более мощной базовой сети и быстро накапливает высокоуровневый контекст. Модуль уточнения внимания перенастраивает контекстные признаки, а модуль слияния признаков объединяет пространственную и контекстную ветви таким образом, чтобы итоговая карта признаков содержала и точные контуры, и семантическое понимание сцены.

Если обозначить предсказанную картину классов сегментации через $p_{i,c}$, а истинную разметку через $y_{i,c}$, то стандартная функция потерь сегментации может быть записана как

$$\mathcal{L}_{\text{seg}} = - \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log p_{i,c}, \quad (34)$$

где N — число пикселей, а C — число семантических классов. Для задачи парсинга лица к этим классам могут относиться кожа, волосы, брови, глаза, губы, внутренние области рта и фон. В ряде реализаций к основной потере добавляются вспомогательные потери на промежуточных масштабах, что улучшает сходимость и устойчивость обучения.

Вероятности $p_{i,c}$ обычно вычисляются через softmax-нормировку логитов $s_{i,c}$:

$$p_{i,c} = \frac{\exp(s_{i,c})}{\sum_{k=1}^C \exp(s_{i,k})}. \quad (35)$$

Такой вид предсказания позволяет интерпретировать сегментацию как покомпонентную классификацию пикселей. Для анонимизации это удобно тем, что маска может быть получена не только как бинарное решение «лицо/не лицо», но и как более тонкая комбинация нескольких лицевых классов, подлежащих замене или сглаживанию при слиянии результата.

Использование в такой схеме базовой сети ResNet-34 объяснимо с инженерной точки зрения. Семейство ResNet вводит остаточные связи, благодаря которым обучение сравнительно глубоких сверточных сетей становится устойчивее [6]. Для одного остаточного блока это можно записать как

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, W) + \mathbf{x}, \quad (36)$$

где $\mathbf{x}$ есть вход блока, $\mathcal{F}$ — изучаемое остаточное преобразование, а W — его параметры. Вариант ResNet-34 обеспечивает разумный баланс между вычислительной стоимостью и выразительной способностью признаков. Для парсинга лица это означает, что модель может работать достаточно быстро, сохраняя при этом способность различать тонкие семантические области лица: кожу, волосы, брови, глаза, губы, внутреннюю часть рта и фон. В результате получаемая маска пригодна не только для грубого выделения прямоугольной области лица, но и для более аккуратной компоновки синтезированного результата в исходное изображение.

С практической точки зрения модель сегментации в конвейере анонимизации решает две задачи. Первая задача состоит в ограничении области замены, чтобы генератор не затрагивал нерелевантные участки кадра. Вторая задача состоит в обеспечении естественного смешивания синтезированного лица с исходным изображением, особенно вдоль границ подбородка, линии роста волос, носогубной области и периорбитальной зоны. Поэтому точность модели парсинга лица влияет не только на эстетическое качество результата, но и косвенно на эффективность анонимизации: плохо выделенная маска может оставить исходные идентифицирующие детали вне зоны замены.

Кроме того, сегментация позволяет управлять тем, какие именно атрибуты будут восприниматься как относящиеся к идентичности. В реальной фотографии биометрически значимыми оказываются не только глаза, нос и рот, но и форма линии подбородка, контур щек, переходы кожи к волосам и часть периферийных областей. Если маска включает слишком узкую внутреннюю область лица, то существенная доля таких признаков остается исходной. Если же маска захватывает слишком широкую область, возникает риск разрушить важные элементы сцены и ухудшить реалистичность результата. Поэтому качество сегментации связано с анонимизацией не опосредованно, а напрямую: именно маска задает компромисс между полнотой замены идентифицирующих признаков и сохранением естественного вида фотографии.

2.5 Модели распознавания лиц как инструмент оценки анонимизации

Для корректной оценки качества анонимизации недостаточно визуально сравнивать изображения до и после замены лица. Необходимо измерять, насколько сильно меняется идентичностное представление изображения в пространстве признаков современных систем распознавания лиц. В данной работе для этой цели используются ArcFace и AdaFace. Эти модели особенно удобны для оценки, поскольку обе относятся к числу сильных современных моделей распознавания лиц, но при этом по-разному организуют функцию потерь и работу с качеством изображения [3, 9].

Общим для ArcFace и AdaFace является представление лица в виде эмбединга фиксированной размерности, который затем нормируется и сравнивается обычно по косинусной мере. Пусть нейросетевая модель вычисляет признак $f_i \in \mathbb{R}^d$ для i -го изображения, а весовой вектор класса обозначен как W_j . После L_2 -нормирования признаков, и весов классификация может быть записана в угловой форме, где решающую роль играет угол между эмбеддингом лица и центром класса на гиперсфере. Такая геометрическая постановка особенно удобна для распознавания лиц, поскольку позволяет непосредственно оптимизировать межклассовую разделимость и внутриклассовую компактность через угловые отступы.

2.5.1 ArcFace

Модель ArcFace была предложена как способ ввести в softmax-классификатор аддитивный угловой отступ, имеющий ясную геометрическую интерпретацию [3]. После нормировки признаков и весов логиты записываются через $\cos \theta_j$, где θ_j есть угол между эмбеддингом и весом класса j . Для истинного класса вводится угловой сдвиг m , а итоговая функция потерь принимает вид

$$L_{\text{ArcFace}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{s \cdot \cos(\theta_{y_i} + m)}}{e^{s \cdot \cos(\theta_{y_i} + m)} + \sum_{j \neq y_i} e^{s \cdot \cos \theta_j}}, \quad (37)$$

где s является масштабным коэффициентом, а y_i обозначает истинный класс для i -го образца. В отличие от более ранних функций потерь с отступом, ArcFace задает отступ непосредственно в угловом пространстве, что делает его интерпретацию особенно прозрачной: для корректной классификации одного и того же человека требуется не просто высокий косинус, а достижение дополнительного геометрического запаса между классами [3].

Если обозначить нормированный эмбеддинг через $\bar{f}_i = f_i / \|f_i\|_2$ и нормированный вес класса через $\bar{W}_j = W_j / \|W_j\|_2$, то

$$\cos \theta_j = \bar{W}_j^\top \bar{f}_i. \quad (38)$$

Тем самым задача классификации переносится на единичную гиперсферу, а различие между идентичностями выражается прежде всего через угловое расстояние. Геодезическое расстояние между двумя эмбеддингами на гиперсфере можно записать как

$$d_{\text{geo}}(z_1, z_2) = \arccos \left(\frac{z_1^\top z_2}{\|z_1\|_2 \|z_2\|_2} \right). \quad (39)$$

Именно поэтому ArcFace особенно удобен для анализа анонимизации: уменьшение косинусного сходства между исходным и преобразованным лицом эквивалентно увеличению угловой дистанции между их идентичностными представлениями.

Для задач оценки анонимизации это важно по двум причинам. Во-первых, ArcFace эмбеддинги образуют хорошо структурированное пространство идентичности, в котором косинусное сходство имеет прямой практический смысл. Во-вторых, модель специально обучена так, чтобы изображения одного человека образовывали компактные кластеры даже при существенных вариациях позы, освещения и выражения лица. Следовательно, если после анонимизации близость между исходным и преобразованным изображением в пространстве ArcFace остается высокой, это означает, что существенная доля идентифицирующих признаков не была устранена.

Архитектурно ArcFace не привязан к одной-единственной базовой сети, однако в практических конфигурациях обычно используется семейство улучшенных остаточных сетей, включая варианты IR-50 и IR-100, специально адаптированные для распознавания лиц [3]. Независимо от конкретной глубины базовой сети, принцип остается общим: сверточная сеть извлекает высокоуровневые признаки, затем формируется компактный эмбеддинг, который нормируется и используется для угловой классификации. Поэтому, рассматривая ArcFace как инструмент оценки, корректно акцентировать внимание не на частных деталях одной реализации, а на геометрии гиперсферического признакового пространства, которая и определяет силу метода.

2.5.2 AdaFace

AdaFace развивает ту же общую гиперсферическую парадигму распознавания лиц, что и ArcFace, но добавляет в нее явную адаптацию к качеству изображения [9]. Авторы исходят из наблюдения, что в реальных данных качество лицевых изображений существенно неоднородно: часть кадров резкая и фронтальная, другая часть содержит шум, размытие, сильные повороты головы

или плохое освещение. Если ко всем примерам применять один и тот же фиксированный margin , это может приводить к неустойчивому обучению, поскольку низкокачественные изображения не должны наказываться так же, как высококачественные.

Центральная идея AdaFace состоит в использовании нормы эмбединга как приближенного индикатора качества изображения. В статье показывается, что норма признака коррелирует с качеством входного лица, а потому может использоваться для адаптивного задания классификационного отступа [9]. Для каждого образца сначала вычисляется нормированная оценка качества

$$g_i = \text{clip}\left(\frac{\|f_i\| - \mu_k}{\sigma_k}, -1, 1\right) \cdot h, \quad (40)$$

где μ_k и σ_k являются скользящими статистиками нормы признака, а h определяет масштаб адаптации. Затем угловой и аддитивный компоненты margin модифицируются как

$$\theta_{y_i} \mapsto \theta_{y_i} + m \cdot g_i, \quad \cos \theta_{y_i} \mapsto \cos \theta_{y_i} - m(1 + g_i), \quad (41)$$

что приводит к качественно-адаптивному варианту функции потерь с отступом [9]. Идея заключается в том, что для низкокачественных примеров отступ уменьшается, а для высококачественных усиливается, благодаря чему обучение становится более согласованным с реальным распределением сложности данных.

В терминах логитов это означает, что вклад истинного класса становится функцией не только угла, но и оцененного качества:

$$\ell_{y_i}^{\text{AdaFace}} = s \cdot \cos(\theta_{y_i} + m g_i) - s \cdot m(1 + g_i). \quad (42)$$

Даже если конкретные инженерные детали реализации могут варьироваться, принцип остается тем же: низкокачественные изображения не должны вносить в обучение столь же жесткое ограничение, как высококачественные. Для задач оценки анонимизации это означает, что AdaFace потенциально чувствительнее к тем случаям, где качество синтезированного лица изменяется вместе с его идентичностью.

С точки зрения архитектуры AdaFace, как и ArcFace, обычно реализуется поверх остаточной базовой сети для извлечения лицевых признаков. Следовательно, принципиальное различие между ArcFace и AdaFace заключается не столько в сверточной части сети, сколько в трактовке классификационного пространства и в механизме задания отступа. ArcFace использует фиксированный угловой отступ, одинаковый для всех примеров, тогда как AdaFace адаптирует силу разделения в зависимости от оцененного качества образца. Именно поэтому совместное использование этих моделей в эксперименте оправдано методологически: если анонимизация оказывается эффективной одновременно относительно ArcFace и AdaFace, можно говорить о большей устойчивости вывода по отношению к различным стратегиям построения биометрического пространства.

Для интерпретации результатов это различие особенно существенно. ArcFace можно рассматривать как модель, в которой проверка деидентификации проводится в жестком, но однородном геометрическом пространстве, тогда как AdaFace дополнительно учитывает вариации качества лицевых изображений. Если после анонимизации сходство падает только в одной из двух моделей, это может означать, что преобразование разрушает идентичность лишь в ограниченном классе условий. Напротив, устойчивое снижение сходства одновременно в ArcFace и AdaFace дает более сильный аргумент в пользу того, что разрушение идентичности не является артефактом конкретной функции потерь или конкретной трактовки качества образца.

2.5.3 Эмбединговое пространство и интерпретация результатов

Поскольку обе рассматриваемые модели работают с компактными эмбедингами на гиперсфере, естественной мерой сходства между лицами выступает косинусная близость. Пусть z_{orig} обозначает

эмбединг исходного изображения, а z_{anon} — эмбединг анонимизированного изображения. Тогда косинусное сходство

$$\text{sim}(z_{\text{orig}}, z_{\text{anon}}) = \frac{z_{\text{orig}}^T z_{\text{anon}}}{\|z_{\text{orig}}\| \|z_{\text{anon}}\|} \quad (43)$$

служит прямым индикатором сохранности идентичности. Чем выше это значение, тем больше вероятность, что система распознавания продолжает воспринимать два изображения как принадлежащие одному человеку. Снижение косинусного сходства после замены лица означает, что идентичностный компонент был ослаблен или заменен. При этом важно учитывать, что абсолютная интерпретация порогов зависит от конкретной модели, ее калибровки и сценария верификации. Поэтому в контексте данной работы ArcFace и AdaFace используются прежде всего как согласованные инструменты сравнительного анализа между состояниями «до» и «после» анонимизации.

Если требуется перейти от непрерывной меры сходства к бинарному решению о совпадении идентичности, можно записать правило верификации в виде

$$\delta(z_{\text{orig}}, z_{\text{anon}}) = \mathbb{I}[\text{sim}(z_{\text{orig}}, z_{\text{anon}}) \geq \tau], \quad (44)$$

где τ — порог верификации, а $\mathbb{I}[\cdot]$ — индикаторная функция. Величина τ на практике подбирается по валидационным данным и отражает компромисс между ложными принятиями и ложными отклонениями. В контексте анонимизации важно, что уменьшение сходства после обработки снижает вероятность выполнения условия $\text{sim} \geq \tau$, а значит уменьшает вероятность того, что анонимизированное изображение будет принято системой как принадлежащее исходному человеку.

3 Методика эксперимента

Экспериментальная часть работы посвящена оценке того, насколько эффективно нейросетевые методы замены лиц разрушают исходную идентичность человека на фотографии. В эксперименте используется первая часть датасета FFHQ, представляющего собой высококачественное собрание портретных изображений людей с широким разнообразием возраста, пола, этнической принадлежности, ракурсов, причесок и условий съемки [8]. Выбор FFHQ для данной задачи оправдан тем, что этот набор данных содержит реалистичные и визуально разнообразные лица, а значит позволяет исследовать поведение алгоритмов анонимизации в условиях, близких к реальным пользовательским фотографиям, а не только на строго контролируемых студийных портретах.

В рассматриваемой постановке анонимизация реализуется как замена лица каждого человека на одно и то же сгенерированное референсное лицо с помощью конвейера FaceFusion. Для генерации анонимизированных изображений используются четыре модели: HyperSwap 1a, HyperSwap 1c, InSwapper FP16 и SimSwap 512. Общая логика обработки для всех вариантов остается одинаковой. Сначала в исходном изображении выделяется и выравнивается лицо. Затем по заданному референсному изображению определяется целевая идентичность, которая должна быть перенесена в область лица исходного человека. После этого модель замены лиц синтезирует новую лицевую область, а модель сегментации `bisenet_resnet_34` формирует маску, по которой результат интегрируется обратно в исходный кадр. Таким образом, все изображения после анонимизации сохраняют исходную сцену, но теряют собственную исходную лицевую идентичность, приобретая вместо нее общую референсную.

Ключевая идея методики состоит в том, что качество анонимизации оценивается не только визуально, но и биометрически. Для этого как исходные, так и анонимизированные изображения пропускаются через две модели распознавания лиц: ArcFace и AdaFace. Для каждого изображения вычисляется эмбединг в соответствующем признаковом пространстве, после чего анализируется сходство между эмбедингами до и после замены лица. Если анонимизация эффективна, то

после применения модели замены лиц косинусная близость между исходным и преобразованным изображением должна систематически снижаться. Иными словами, хорошие визуальные результаты сами по себе недостаточны; требуется, чтобы системы распознавания переставали устойчиво сопоставлять результат с исходным человеком.

Такая постановка эксперимента позволяет интерпретировать анонимизацию как операцию, действующую на распределение эмбеддингов. Для набора исходных изображений можно рассматривать совокупность попарных сходств между состояниями «до» и «после» обработки. Если модель замены лиц действительно подменяет идентичность, то распределение этих сходств должно смещаться в сторону меньших значений. При этом полезно не ограничиваться единичными примерами: отдельное изображение может оказаться простым или, наоборот, трудным для деидентификации из-за удачного ракурса, окклюзии, макияжа или освещения. Поэтому использование множества изображений из первой части FFHQ позволяет анализировать не единичный случай, а более устойчивую картину поведения моделей на разнообразных портретах.

Использование одновременно ArcFace и AdaFace делает эксперимент более содержательным. ArcFace задает сильный базовый стандарт распознавания в гиперсферическом признаковом пространстве с фиксированным угловым отступом. AdaFace, в свою очередь, позволяет проверить устойчивость результата в модели, где отступ адаптируется к качеству изображения. Если деидентификация наблюдается в обоих пространствах признаков, это служит более убедительным основанием считать анонимизацию успешной, чем анализ только в рамках одной модели. Кроме того, сопоставление результатов для разных моделей замены лиц позволяет исследовать, какие архитектурные подходы лучше нарушают исходную биометрическую связь при сохранении реалистичности изображения.

Следует также подчеркнуть, что использование одного и того же референсного лица для всех изображений задает строгую и удобную экспериментальную схему. С одной стороны, это снижает вариативность, связанную с выбором разных целевых идентичностей, и тем самым упрощает сравнение моделей между собой. С другой стороны, такая постановка близка к практической задаче унифицированной анонимизации, где для большого числа фотографий требуется применять единый, визуально согласованный способ замены лиц. В этом смысле эксперимент исследует не только вопрос о том, можно ли заменить одно лицо на другое, но и вопрос о том, насколько стабильно современные модели замены лиц справляются с массовой заменой большого числа различных идентичностей на одну общую целевую идентичность.

Тем самым эксперимент имеет сравнительный характер. Он не сводится к демонстрации одного отдельного примера замены лица, а направлен на систематическое сопоставление нескольких современных моделей замены лиц в единой постановке, на одном наборе данных и при единой целевой идентичности. Такая методика позволяет интерпретировать анонимизацию как измеряемое изменение положения изображения в пространстве признаков современных систем распознавания лиц и тем самым связывает визуальную обработку изображений с формальной оценкой уровня защиты приватности.

Список литературы

- [1] Renwang Chen и др. “SimSwap: An Efficient Framework For High Fidelity Face Swapping”. В: *arXiv preprint arXiv:2106.06340* (2021). URL: <https://arxiv.org/abs/2106.06340>.
- [2] DeepWiki. *HyperSwap System Documentation for facefusion/facefusion-labs*. 2025. URL: <https://deepwiki.com/facefusion/facefusion-labs/2-hyperswap-system> (дата обр. 21.05.2026).
- [3] Jiankang Deng и др. “ArcFace: Additive Angular Margin Loss for Deep Face Recognition”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, с. 4690—4699. DOI: 10.1109/CVPR.2019.00482.

- [4] Ivan Evtimov и др. “FoggySight: A Scheme for Facial Lookup Privacy”. В: *Proceedings on Privacy Enhancing Technologies* 2021.2 (2021), с. 204—226. DOI: 10.2478/popets-2021-0028.
- [5] FaceFusion Labs. *FaceFusion Labs Repository*. 2025. URL: <https://github.com/facefusion/facefusion-labs> (дата обр. 21.05.2026).
- [6] Kaiming He и др. “Deep Residual Learning for Image Recognition”. В: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, с. 770—778. DOI: 10.1109/CVPR.2016.90.
- [7] InsightFace. *InsightFace InSwapper Documentation and Examples*. 2025. URL: https://github.com/deepinsight/insightface/tree/master/examples/in_swapper (дата обр. 21.05.2026).
- [8] Tero Karras, Samuli Laine и Timo Aila. “A Style-Based Generator Architecture for Generative Adversarial Networks”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, с. 4401—4410. DOI: 10.1109/CVPR.2019.00453.
- [9] Minchul Kim, Anil K. Jain и Xiaoming Liu. “AdaFace: Quality Adaptive Margin for Face Recognition”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022, с. 18750—18759. DOI: 10.1109/CVPR52688.2022.01821.
- [10] Tao Li и др. “AnonymousNet: Natural Face De-Identification with Measurable Privacy”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2019, с. 56—65. DOI: 10.1109/CVPRW.2019.00015.
- [11] neuralchen. *SimSwap Official Repository*. 2025. URL: <https://github.com/neuralchen/SimSwap> (дата обр. 21.05.2026).
- [12] Slobodan Ribarić, Ari Moeslund и Nicolae Pavesić. “De-identification for privacy protection in multimedia content: A survey”. В: *Signal Processing: Image Communication* 47 (2016), с. 131—151. DOI: 10.1016/j.image.2016.05.020.
- [13] Tiancheng Sun и др. “Natural and Effective Obfuscation by Head Inpainting”. В: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2018, с. 5050—5059. DOI: 10.1109/CVPR.2018.00530.
- [14] Yaniv Taigman и др. “DeepFace: Closing the Gap to Human-Level Performance in Face Verification”. В: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2014, с. 1701—1708. DOI: 10.1109/CVPR.2014.220.
- [15] Changqian Yu и др. “BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation”. В: *Proceedings of the European Conference on Computer Vision*. 2018, с. 325—341. DOI: 10.1007/978-3-030-01261-8_20.